MIMIC-IV 임상 텍스트의 피처 관계 규명을 위한 단계적 단어 제거 및 전처리 전략 비교 연구

윤진혁(지도 교수님), 이진아

숭실대학교...

jhyun@ssu.ac.kr, icandoitjina@naver.com,

Comparative Study on Stepwise Word Removal and Preprocessing Strategies for Identifying Feature Relationships in MIMIC-IV Clinical Notes

Yun JinHyuk, Lee JinA, ...

Soongsil University

jhyun@ssu.ac.kr, icandoitjina@naver.com

요 약

임상 자연어 처리(NLP)에서 퇴원 요약지(Discharge Summary)는 환자의 상태를 파악하는 중요한 데이터이나, 예측 시점 이후의 정보(Data Leakage)가 포함되어 모델이 잘못된 피처 관계를 학습할 위험이 있다. 본 연구는 효과적인 모델 학습을 위해 텍스트 내 특정 단어와 섹션을 단계적으로 제거하는 전처리 실험을 수행하고, 이에 따른 모델의 성능 변화와 피처 중요도(Feature Importance)의 추이를 분석하였다. MIMIC-IV 데이터를 활용하여 **(1) 전체 텍스트 사용, (2) 결과 관련 섹션 제거, (3) 규칙 기반 문장 필터링**의 세 가지 전처리 단계를 비교 실험하였다. 연구 결과, 단순한 불용어 처리를 넘어선 **'White-list 기반 섹션 추출'** 방식이 '사망(Expired)'과 같은 결과론적 단어와 예측 타겟 간의 허위 상관관계(Spurious Correlation)를 제거하고, '저혈압(Hypotension)' 등 실질적인 임상 피처 간의 관계를 학습하는 데 효과적임을 확인하였다.

1. 서 론

의료 데이터, 특히 비정형 텍스트 데이터는 전처리 방식에 따라 모델이 학습하는 피처의 성격이 극명하게 달라진다. 기존 연구들은 텍스트의 풍부한 정보를 활용하기 위해 전체 문서를 임베딩하는 방식을 주로 사용했으나, 이는 '사망 시각', '퇴원 장소' 등 결과 지표가 입력 데이터에 포함되는 문제를 야기한다. 이러한 단어들은 타겟 레이블과 강력한 상관관계를 가지지만, 이는 인과관계가 아닌 데이터 유출에 의한 결과이다.

본 연구는 데이터 전처리 과정에서 **어떤 단어와 정보를 제거하는 것이 모델이 환자의 상태를 올바르게 파악하는 데 기여하는지**를 규명하고자 한다. 이를 위해 다양한 수준의 텍스트 제거(Text Removal) 실험을 설계하고, 각 전처리 단계가 모델의 예측 성능과 학습하는 핵심 피처에 미치는 영향을 정량적으로 분석하여, 의료 텍스트 마이닝을 위한 최적의 전처리 가이드라인을 제시한다.

2. 연구 방법

2.1 실험 데이터 및 전처리 단계 설정 MIMIC-IV v2.2 의 퇴원 요약지 329,940 건을 대상으로 하였으며, 데이터 전처리가 모델 학습에 미치는 영향을 분석하기 위해 다음과 같이 세 가지 실험군을 설정하였다.

- **실험 A (Baseline):** 특수문자 제거 등 기본적인 정제만 수행하고 전체 텍스트를 사용.
- **실험 B (Section Removal):** 'Hospital Course', 'Discharge Disposition' 등 미래 시점의 정보가 포함된 특정 섹션 전체를 제거.
- **실험 C (Sentence Filtering & Extraction):** 정규표현식을 활용하여 'Chief Complaint', 'Physical Exam' 등 입원 초기 정보(White-list)만 추출하고, "Patient died"와 같이 결과가 명시된 문장을 규칙 기반으로 필터링.

2.2 모델링 및 피처 분석

텍스트의 벡터화를 위해 `Bio_ClinicalBERT` 를 활용하였으며, 입력 길이 제한을 극복하기 위해 문서를 분할하여 임베딩하는 Chunking 기법을 적용하였다. 분류기로는 XGBoost 와 로지스틱 회귀를 사용하였으며, 각 실험 단계별로 모델이 중요하게 판단한 상위 피처(Top-K Features)를 추출하여 단어 제거에 따른 모델의 학습 패턴 변화를 분석하였다.

3. 실험 및 결과

3.1 전처리 단계별 성능 및 피처 변화

실험 결과, 전처리 방식에 따라 모델의 성능 지표와 중요 피처가 확연히 달라짐을 확인하였다.

전처리 단계	AUROC	주요 학습 피처(Top Words)	비고
(A)전체 텍스트	**0.9995**	expired, deceased, died, time of death	데이터 유출 발생
(B)섹션 제거	**0.9727**	unresponsive, failure, comfort measures	결과 정보 일부 잔존
(C)문장 필터링	**0.9552**	admission, hypotension, intubated, history	임상적 특징 학습

전체 텍스트를 사용한 **실험 A** 는 AUROC 0.9995 라는 비현실적인 성능을 보였으나, 주요 피처 분석 결과 'expired', 'deceased' 등 타겟 레이블을 직접적으로 암시하는 단어들이 상위를 차지하였다. 이는 모델이 환자의 상태가 아닌 결과 텍스트를 학습했음을 의미한다. 반면, 미래 정보를 과감히 제거한 **실험 C** 에서는 AUROC 가 0.9552 로 조정되었으나, 주요 피처가 'hypotension(저혈압)', 'intubated(삽관)' 등 실제 입원 시점의 위중증도를 나타내는 단어들로 변화하였다. 이는 제안된 전처리 방식이 피처 간의 유의미한 임상적 관계를 성공적으로 보존했음을 시사한다.

3.2 정형 데이터와의 관계 분석

최적화된 텍스트 전처리를 거친 임베딩 벡터를 정형 데이터(활력 징후 등)와 결합(Late Fusion)하여 학습한 결과, 텍스트 데이터가 정형 데이터의 결측이나 정보 부재를 보완하며 예측 정확도를 향상시키는 것을 확인하였다. 이는 불필요한 단어의 제거가 오히려 모델이 다른 유효한 피처(Feature)들에 집중하게 함으로써 전체적인 학습 효율을 높임을 보여준다.

4. 결 론

본 연구는 의료 텍스트 데이터 분석에 있어 **단어 및 섹션 제거와 같은 전처리 전략**이 모델의 신뢰성에 미치는 영향을 실험적으로 증명하였다. 단순히 많은 양의 텍스트를 학습시키는 것보다, 예측 시점에 알 수 없는 미래 정보를 담은 단어들을 선별적으로 제거하는 것이 피처 간의 올바른 관계를 학습하는 데 필수적이다. 특히 **White-list 기반의 섹션 추출 전처리**는 데이터 유출을 방지하면서도 임상적으로 타당한 인과관계를 모델링할 수 있는 가장 효과적인 방법임을 확인하였다. 향후 연구에서는 이러한 전처리 과정을 자동화할 수 있는 자연어 처리 알고리즘 개발이 필요할 것이다.

참고문헌

1. Johnson, A. E., et al. "MIMIC-IV, a freely accessible electronic health record dataset." Scientific Data, 10(1), 1, 2023.

2. Kaufman, S., et al. "Leakage in data mining: Formulation, detection, and avoidance." ACM Transactions on Knowledge Discovery from Data, 6(4), 15, 2012.